

# Ressources pour la modélisation IA 100 % Fon (Fongbé)

Meilleures sources : Unicode • Dictionnaires • Corpus texte & parole • Modèles existants

Le Fon (Fṵṵngbè / Fongbé) est une langue gbe tonale parlée principalement au Bénin (environ 2 millions de locuteurs). C'est une langue à faible ressource. Les corpus ci-dessous constituent l'état de l'art disponible en 2026 pour entraîner des modèles d'IA (LLM, ASR, TTS, traduction, NER, etc.) entièrement centrés sur le Fon.

## 1. Unicode & Orthographe officielle (critique pour l'IA)

L'alphabet officiel (norme béninoise / SIL) utilise le latin étendu avec les caractères spéciaux suivants :

- Lettres : Ṽ, Ṷ, ṷ + digraphes **gb**, **kp**, **ny**
- Tons (diacritiques essentiels) :
  - Haut : ´ (ex. xó) – Bas : ` (ex. ṵò) – Moyen : ¯ – Contours : Ṹ ^

**Recommandation technique** : Toujours normaliser en **NFD** (diacritiques décomposés) pour préserver les tons. Polices recommandées : Gentium Plus, Charis SIL, Noto Sans, Arial Unicode MS.

Claviers utiles : Clavier web Fongbé (Bonaventure Dossou), application Android « Clavier Fongbé », Clavier des langues béninoises (fongbe.bj).

## 2. Dictionnaires & Lexiques

| Ressource                                                           | Type                          | Qualité      | Accès                              |
|---------------------------------------------------------------------|-------------------------------|--------------|------------------------------------|
| Höftmann (2003) – Dictionnaire Fon-Français + esquisse grammaticale | Référence académique          | ★★★★★        | Livre (Köppe Verlag)               |
| Höftmann (2012) – Dictionnaire Français-Fon                         | Complet                       | ★★★★★        | Livre                              |
| Lexilogos Fon                                                       | En ligne FR ↔ Fon             | ★★★★         | lexilogos.com/fon_dictionnaire.htm |
| IamYourClounon – Dictionnaire numérique langues béninoises          | App mobile (>20 000 entrées)  | ★★★★★ (2025) | Play Store / App Store             |
| fongbebenin.com                                                     | Vocabulaire + phrases + audio | ★★★★         | Site gratuit                       |
| Segurola / Rassinoux / Delafosse                                    | Classiques historiques        | ★★★          | Archives / Internet Archive        |

## 3. Corpus texte (NLP / Traduction / LLM)

- **FFR Dataset** (Dossou & Emezue) – plus grand corpus parallèle Fon-Français (jusqu'à ~117 000 phrases). Zenodo / GitHub.
- **Fon-French Daily Dialogues** – 25 377 phrases de dialogues quotidiens crowdsourcés (Zenodo 4432712).
- **xP3 / xP3mt** (BigScience) – données multitâches incluant le Fon.
- Wikipedia Fon (version existante) + UDHR en Fon (Unicode.org).
- Travaux Masakhane, GitHub de Bonaventure Dossou / Chris Emezue.

## 4. Corpus parole (ASR / TTS / Speech Translation)

| Corpus          | Durée / Taille | Contenu                                | Accès                             |
|-----------------|----------------|----------------------------------------|-----------------------------------|
| FFSTC / FFSTC 2 | 31 h → 61 h    | Fongbé → Français (speech translation) | arXiv 2403.05488 + extension 2025 |
| ALFFA Project   | ~6–12 h        | ASR Fongbé (transcriptions avec tons)  | GitHub / Hugging Face             |

|                                |               |                                                  |              |
|--------------------------------|---------------|--------------------------------------------------|--------------|
| Professor/fongbe-speech-zenodo | ~12,3 h       | Corpus unifié (ALFFA + Zenodo), tons préservés   | Hugging Face |
| iafacile/fon-acoustic-corpus   | 7 000+ pistes | Audio synthétique (liturgique, narrative, chant) | Hugging Face |
| Modèles ASR prêts              | —             | Professor/mms-300m-fongbe (SOTA ~9,5 % WER)      | Hugging Face |

## 5. Outils & Modèles IA déjà disponibles

- **ASR** : Professor/mms-300m-fongbe (fine-tuned MMS, préserve les diacritiques) – Hugging Face
- **Traduction** : Travaux FFR (Fon ↔ Français) de Dossou & Emezue
- **Multitask** : FonMTL (NER + POS) – GitHub bonaventuredossou/multitask\_fon
- **Synthèse vocale** : Travaux HMM/HTS et applications mobiles (2025)
- Clavier + input : essentiels pour collecter de nouvelles données propres

## 6. Sites & Portails prioritaires

- **fongbebenin.com** – Apprentissage + corpus audio (~1 000 phrases)
- **fongbe.bj** / BéninLangues
- **Lexilogos** + clavier intégré
- **Hugging Face** (rechercher « fon » ou « fongbe »)
- Masakhane NLP / Lanfrica / Lelapa AI (communauté africaine)

## 7. Recommandations pour une modélisation IA 100 % Fon

1. **Toujours conserver les diacritiques tonals** (normalisation NFD). Les modèles qui les suppriment perdent beaucoup d'information sémantique.
2. Combiner : texte parallèle FFR + Wikipedia Fon + parole FFSTC 2 + ALFFA + Zenodo unifié.
3. Commencer par fine-tuning de modèles multilingues africains (AfriHuBERT, MMS, BLOOMZ, etc.).
4. Collecte supplémentaire recommandée : transcriptions de chants traditionnels (Zinli, Tchinkounmè...), radios béninoises, YouTube en Fongbé.

---

Document généré le 26 septembre 2026 • Sources : arXiv, Hugging Face, Lexilogos, Zenodo, fongbebenin.com, recherches web 2026

Liste non exhaustive – les ressources évoluent rapidement. Vérifier les dépôts Hugging Face et arXiv pour les mises à jour.